

Perbandingan Model SARIMAX dengan Model LSTM dalam Peramalan Jumlah Wisatawan Mancanegara ke Indonesia

Abie Septian Wibowo¹, Sabitala Dinika², Muhammad Fauzan Nur Rasendriya³,
Cameliya Ulya Hidayah⁴, Laily Nissa Atul Mualifah⁵, Windi Pangesti⁶

^{1,2,3,4,5,6} Program Studi Statistika dan Sains Data, IPB University

Jl. Raya Darmaga Kampus IPB, Babakan, Kec. Dramaga, Kabupaten Bogor, Jawa Barat, Indonesia

Email: abieseptian@apps.ipb.ac.id¹, sbtadinika@apps.ipb.ac.id², rasendriyafauzan@apps.ipb.ac.id³,
cameliyaulya@apps.ipb.ac.id⁴, lailyatul@apps.ipb.ac.id⁵, windi_pangesti@apps.ipb.ac.id⁶

Korespondensi penulis : lailyatul@apps.ipb.ac.id

Abstrak

Sektor pariwisata merupakan pilar penting dalam perekonomian Indonesia. Wisatawan mancanegara menjadi salah satu yang berkontribusi dalam peningkatan penerimaan devisa pariwisata. Namun, pada masa COVID-19, terjadi penurunan jumlah wisatawan mancanegara. Penelitian ini bertujuan untuk membandingkan pemodelan SARIMAX dengan LSTM pada data kunjungan wisatawan mancanegara ke Indonesia. Hasil perbandingan kinerja model menggunakan RMSE dan MAPE menunjukkan bahwa LSTM memiliki performa lebih baik daripada SARIMAX, dengan RMSE sebesar 106.089,12 dan MAPE 7,46% yang lebih rendah dibandingkan RMSE 123.288,40 dan MAPE 8,53% pada SARIMAX. Temuan ini bermakna bahwa LSTM lebih mampu menangkap pola kompleks dan dinamika fluktuatif pada data wisatawan mancanegara dibandingkan model statistik konvensional.

Kata Kunci: LSTM, pariwisata, perbandingan model, SARIMAX, wisatawan mancanegara.

Abstract

The tourism sector is a crucial pillar of the Indonesian economy. Foreign tourists contribute to the increase in tourism foreign exchange earnings. However, during the COVID-19 pandemic, the number of foreign tourists has decreased. This study aims to compare SARIMAX modeling with LSTM on data on foreign tourist visits to Indonesia. The results of the model performance comparison using RMSE and MAPE show that LSTM outperforms SARIMAX, with an RMSE of 106,089.12 and a MAPE of 7.46%, lower than the RMSE of 123,288.40 and a MAPE of 8.53% in SARIMAX. This finding indicates that LSTM is better able to capture complex patterns and fluctuating dynamics in foreign tourist data compared to conventional statistical models.

Keywords: LSTM, tourism, model comparison, SARIMAX, international tourist arrivals.

1. Pendahuluan

Sektor pariwisata merupakan salah satu sektor strategis dalam pembangunan ekonomi Indonesia. Kontribusinya terhadap produk domestik bruto, penciptaan lapangan kerja, dan penerimaan devisa menjadikan pariwisata sebagai pilar penting dalam perekonomian nasional. Peningkatan jumlah wisatawan mancanegara (wisman) berkontribusi langsung terhadap naiknya penerimaan devisa negara melalui sektor pariwisata, karena semakin banyak wisatawan asing yang datang, semakin besar pula cadangan devisa yang dihasilkan dari sektor pariwisata [1][2].

Jumlah wisman yang berkunjung ke Indonesia menunjukkan tren peningkatan yang konsisten pada masa sebelum pandemi COVID-19. Data Badan Pusat Statistik (BPS) mencatat bahwa kunjungan wisman terus meningkat dari tahun ke tahun, mencapai 1,2 juta kunjungan pada Januari 2020. Namun, sejak Februari 2020, pandemi COVID-19 menyebabkan penurunan drastis dalam dinamika pariwisata global, termasuk di Indonesia [3]. Bahkan pada Maret 2020, penurunan kunjungan wisman tercatat mencapai sekitar 63% dibanding Maret 2019 [4]. Sementara tahun 2021, jumlah kunjungan wisman hanya tercatat sebanyak 1,56 juta kunjungan, turun sekitar 61% dibandingkan dengan jumlah kunjungan wisman pada tahun 2020, menjadi titik terendah dalam satu dekade terakhir. Penurunan ini tidak hanya berdampak pada sektor pariwisata itu sendiri, tetapi juga pada penerimaan devisa, tenaga kerja, dan sektor pendukung lainnya [5]. Pemulihan sektor pariwisata mulai terlihat pada tahun 2022 seiring dengan diperkenalkannya kampanye Wonderful Indonesia Rebound [6]. Berdasarkan data BPS kunjungan wisman meningkat dari 1,56 juta kunjungan di tahun 2021 menjadi 5,89 kunjungan wisman di tahun 2022.

Penelitian sebelumnya telah menunjukkan penerapan metode pemodelan deret waktu untuk meramalkan jumlah kunjungan wisman. Penelitian [7] menggunakan metode *Seasonal Autoregressive Integrated Moving Average with Exogenous Variables* (SARIMAX) dalam analisis peramalan dan terbukti mampu menangkap pola musiman serta pengaruh variabel eksternal secara efektif. Sementara itu, penelitian [8] menerapkan metode *Long Short-Term Memory* (LSTM) untuk memprediksi jumlah kunjungan wisatawan dan menghasilkan performa prediksi yang baik pada data berurutan jangka panjang. Namun, hingga saat ini belum terdapat penelitian yang secara langsung membandingkan kinerja metode SARIMAX dan LSTM dalam meramalkan jumlah kunjungan wisman.

Penelitian ini dilakukan untuk membandingkan kinerja antara model berbasis statistik, seperti SARIMAX, dan model berbasis *deep learning*, seperti LSTM pada data jumlah kunjungan wisman ke Indonesia. Setiap metode dievaluasi berdasarkan akurasi prediksi pada data uji sehingga dapat diidentifikasi model yang paling tepat dalam menangkap pola tren, musiman, dan perubahan struktural pada data kunjungan wisman. Hasil perbandingan ini diharapkan memberikan gambaran metode peramalan yang lebih andal untuk mendukung pengambilan keputusan di sektor pariwisata.

2. Metode Penelitian

2.1 Data Penelitian

Data yang digunakan dalam penelitian ini berasal dari Badan Pusat Statistik (BPS) Indonesia, berupa jumlah kunjungan bulanan wisman ke Indonesia dari Januari 1998 hingga Agustus 2025. Total terdapat 332 amatan, yang kemudian dibagi menjadi 312 data

latih yaitu dari periode Januari 1998 sampai Desember 2023 dan 20 data uji yaitu dari Januari 2024 sampai Agustus 2025.

2.2 Seasonal Autoregressive Integrated Moving Average with Exogenous Variables (SARIMAX)

SARIMAX merupakan pengembangan dari model *Autoregressive Integrated Moving Average* (ARIMA) yang mampu menangani pola musiman (*seasonal pattern*) dan memasukkan variabel eksogen (*exogenous variables*) ke dalam proses peramalan. Model ini sering digunakan pada data deret waktu yang menunjukkan adanya tren, fluktuasi berulang dalam periode tertentu, serta ketika terdapat faktor lain di luar waktu yang memengaruhi variabel respon [9]. Secara umum, bentuk model SARIMAX dapat dinotasikan sebagai SARIMAX(p,d,q)(P,D,Q)^s. Dalam notasi tersebut, p, d, dan q masing-masing merepresentasikan orde komponen *autoregressive* (AR), *differencing*, dan *moving average* (MA) untuk bagian non-musiman. Sementara itu, P, D, dan Q menunjukkan orde AR, *differencing*, dan MA untuk komponen musiman. Nilai s digunakan untuk menyatakan panjang periode musiman. Sehingga, bentuk umum model SARIMAX dapat ditulis seperti persamaan berikut:

$$\phi_p(B)\Phi_p(B^s)(1-B)^d(1-B^s)^DY_t = \theta_q(B)\Theta_q(B^s)a_t + \beta_1X_{1,t} + \beta_2X_{2,t} + \dots + \beta_kX_{k,t} \quad (1)$$

Dengan:

B	: operator backshift ($BY_t = Y_{t-1}$)
ϕ, Φ	: koefisien parameter AR non-musiman dan musiman
θ, Θ	: koefisien parameter MA non-musiman dan musiman
$(1-B)^d$	: differencing non-musiman ke-d
$(1-B^s)^D$	: differencing musiman ke-D
Y_t	: nilai aktual pada waktu ke-t
a_t	: komponen error acak pada waktu ke-t
β_k	: koefisien pengaruh variabel eksogen ke-k
$X_{k,t}$	: variabel eksogen ke-k pada waktu ke-t

Variabel eksogen yang digunakan terdiri atas tiga variabel dummy, yaitu X1, X2, dan X3, yang masing-masing bernilai 1 pada periode yang direpresentasikan dan bernilai 0 pada periode lainnya. X1 merepresentasikan masa awal pandemi pada Maret hingga April 2020, ketika terjadi penurunan tajam jumlah kunjungan wisatawan mancanegara ke Indonesia. X2 mencerminkan fase pembatasan perjalanan internasional yang berlangsung dari Mei 2020 hingga Maret 2022. Sementara itu, X3 menggambarkan fase pemulihan sektor pariwisata sejak April 2022 sampai Agustus 2025, seiring dengan pelonggaran kebijakan dan meningkatnya kembali aktivitas perjalanan internasional.


Dalam pemodelan SARIMAX, pemilihan model terbaik dilakukan berdasarkan nilai *Akaike Information Criterion* (AIC) terkecil. Semakin rendah nilai AIC, semakin baik model tersebut dalam menyeimbangkan tingkat kecocokan dan kompleksitas [10]. Persamaan AIC ditunjukkan pada persamaan berikut:

$$AIC = 2k - 2 \ln(L) \quad (2)$$

dengan k adalah jumlah parameter dalam model dan L adalah nilai *likelihood* maksimum model.

2.3 Long Short-Term Memory (LSTM)

LSTM merupakan pengembangan dari arsitektur *Recurrent Neural Network* (RNN) yang dirancang untuk mengatasi keterbatasan RNN dalam memproses data berurutan jangka panjang. LSTM menggunakan mekanisme *gate* untuk mengatur aliran informasi dalam *memory cell* sehingga mampu mempelajari ketergantungan jangka panjang secara efektif. Mekanisme ini terdiri dari tiga *gate*, yaitu *input gate* yang menambahkan informasi baru, *forget gate* yang membuang informasi yang tidak relevan, dan *output gate* yang memperbarui *hidden state* pada setiap *time step* [11]. Arsitektur LSTM ditunjukkan pada Gambar 1.



Gambar 1. Arsitektur LSTM [12]

Hubungan antar gerbang (*gate*) dinyatakan dalam bentuk persamaan matematis berikut:

$$f_t = \sigma(W_f \cdot [h_{t-1}, x_t] + b_f) \quad (3)$$

$$i_t = \sigma(W_i \cdot [h_{t-1}, x_t] + b_i) \quad (4)$$

$$\tilde{C}_t = \tanh(W_c \cdot [h_{t-1}, x_t] + b_c) \quad (5)$$

$$C_t = f_t * C_{t-1} + i_t * \tilde{C}_t \quad (6)$$

$$o_t = \sigma(W_o \cdot [h_{t-1}, x_t] + b_o) \quad (7)$$

$$h_t = o_t * \tanh(C_t) \quad (8)$$

Dengan f_t , i_t , dan o_t masing-masing adalah *forget*, *input*, dan *output gate*, sedangkan C_t menunjukkan *cell state* pada waktu ke- t . Fungsi aktivasi σ menunjukkan *sigmoid function* dan $\tanh$ merupakan fungsi hiperbolik tangens [12].

Dalam membangun model LSTM, kinerja model ditingkatkan melalui penyesuaian kombinasi *hyperparameter*, seperti jumlah *neuron* per *layer*, *epoch*, dan *batch size* [13]. Penentuan kombinasi optimal dilakukan menggunakan *grid search*, yaitu dengan mengevaluasi seluruh kombinasi *hyperparameter* yang telah ditentukan [14]. Karakteristik model yang tercantum pada Tabel 1 adalah dasar untuk pemodelan yang dilakukan dalam penelitian ini.

Tabel 1. Arsitektur dan Hyperparameter Model LSTM

Karakteristik	Spesifikasi
Arsitektur	2 layer LSTM dengan 50 unit <i>neuron</i> dan 1 <i>dense layer</i>
Optimizer	Adaptive Moment Estimation (ADAM)
Loss function	RMSE
Look back	12
Batch Size	16; 32; 64
Epoch	50;100
Learning rate	0,01; 0,001

2.4 Perbandingan Model

Dalam penelitian ini, pemilihan model terbaik dilakukan dengan membandingkan nilai *Mean Absolute Percentage Error* (MAPE) dan *Root Mean Squared Error* (RMSE) pada data uji. MAPE adalah ukuran akurasi peramalan yang dihitung sebagai rata-rata dari seluruh persentase kesalahan, tanpa mempertimbangkan arah kesalahan tersebut [15]. Rumus perhitungan MAPE dapat dilihat pada Persamaan 9.

$$MAPE = \frac{1}{n} \sum_{t=1}^n \frac{|Y_t - \hat{Y}_t|}{Y_t} \quad (9)$$


Dengan n menyatakan jumlah amatan, Y_t nilai aktual pada waktu ke- t , dan $\hat{Y}_t$ nilai prediksi model pada waktu ke- t . Sedangkan, RMSE merupakan ukuran evaluasi berbasis kuadrat yang menghitung rata-rata besar kesalahan dengan mengambil akar kuadrat dari selisih kuadrat rata-rata antara nilai prediksi dan data aktual [10]. Rumus perhitungan RMSE disajikan pada Persamaan 10.

$$RMSE = \sqrt{\frac{\sum_{t=1}^n (Y_t - \hat{Y}_t)^2}{n}} \quad (10)$$

3. Hasil dan Pembahasan


3.1 Eksplorasi Data

Data dieksplorasi terlebih dahulu dengan membagi data menjadi data latih dan uji. Pembagian data dilakukan dengan menggunakan 312 observasi pertama sebagai data latih, yaitu dari Januari 1998 sampai Desember 2023 dan 20 observasi terakhir sebagai data uji, termasuk juga dengan variabel eksogen yang digunakan. Pembagian data ini bertujuan untuk memastikan bahwa model dibangun menggunakan pola historis yang panjang dan stabil, termasuk tren jangka panjang serta pola musiman yang konsisten sebelum periode prediksi. Sementara itu, 20 data uji digunakan untuk mengevaluasi kemampuan model dalam memproyeksikan nilai di luar sampel, sehingga performanya dapat dinilai secara objektif.



Gambar 2. Plot Deret Waktu Total Kunjungan Wisatawan Mancanegara

Data kunjungan wisman dari Januari 1998 hingga Agustus 2025 menunjukkan pola musiman yang tampak jelas berulang setiap tahun. Dalam jangka panjang, terlihat tren peningkatan yang stabil hingga sekitar 2019, mencerminkan pertumbuhan sektor pariwisata sebelum pandemi. Memasuki 2020, kurva turun tajam sebagai dampak langsung COVID-19 yang menghentikan mobilitas global dan membuat angka kunjungan menurun drastis dibandingkan sebelumnya. Setelah masa tersebut, grafik menunjukkan tanda-tanda pemulihan yang konsisten. Jumlah wisman mulai meningkat kembali dan perlahan bergerak mendekati pola normal pra-pandemi, meskipun tampak belum sepenuhnya kembali ke level sebelumnya.




Gambar 3. Plot Deret Waktu Total Kunjungan Wisatawan Mancanegara Tahun 2017 – 2020

Peninjauan dilakukan dengan menelusuri pola pada rentang waktu yang lebih sedikit untuk mengidentifikasi pola musiman pada data. Plot digambarkan dari Februari 2017 sampai dengan Januari 2020 dengan menandakan dua titik yaitu pada bulan Agustus dan Desember. Pada titik bulan Agustus, terlihat jumlah kunjungan wisman lebih tinggi dibanding bulan-bulan lainnya, sementara pada titik bulan Desember tampak jumlah kunjungan wisman lebih tinggi dibanding bulan sebelum dan setelahnya. Dari sini, dapat terlihat pola musiman dari jumlah kunjungan wisman, sehingga akan dilakukan pemodelan dengan menggunakan pendekatan pemodelan dengan musiman yaitu SARIMA dengan tambahan eksogen *dummy* yang telah dibuat sebelumnya, sehingga model yang akan dibentuk adalah SARIMAX.


3.2 Pemodelan SARIMAX

Pemodelan dilakukan dengan terlebih dahulu memeriksa kestasioneran data dalam rata-rata dan ragam. Pemeriksaan kestasioneran dalam ragam menggunakan Box-Cox menghasilkan rentang λ optimal antara 0,41 hingga 0,74. Hasil ini menunjukkan bahwa data tidak stasioner dalam ragam, sehingga perlu dilakukan transformasi data. Selain kestasioneran dalam ragam, pemeriksaan kestasioneran dalam rata-rata juga menunjukkan bahwa data tidak stasioner dalam rata-rata. Hal tersebut terlihat baik secara eksploratif melalui plot ACF yang menurun perlahan dan juga hasil p -value uji ADF sebesar 0,2512 yang artinya tidak signifikan pada taraf nyata 5% sehingga perlu dilakukan *differencing* pada data.




Gambar 4. (a) Plot Box-Cox dan (b) Plot ACF Data Latih

Data dilakukan transformasi akar karena selang optimal data mencakup nilai 0,5. Hasilnya, kestasioneran dalam ragam sudah terpenuhi, dapat dilihat pada Gambar 5(a) yang menghasilkan rentang λ telah memuat angka satu, lebih tepatnya berkisar antara 0,82 hingga 1,48. Sementara itu, kestasioneran dalam rata-rata ditangani dengan melakukan *differencing* satu kali setelah transformasi. Hasilnya, baik dalam komponen non-musiman maupun musimannya telah terpenuhi. Pola pada Gambar 5(b) tidak lagi menunjukkan penurunan secara perlahan dan juga p -value uji ADF lebih kecil dari 0,01 yang artinya signifikan pada taraf nyata 5%, menandakan data telah stasioner dalam rata-rata.



Gambar 5. (a) Plot Box-Cox Data Latih Setelah Transformasi dan (b) Plot ACF Data Latih Setelah Transformasi dan *Differencing*

Setelah dilakukan penanganan, kestasioneran rata-rata dan ragam sudah seluruhnya terpenuhi. Selanjutnya, dilakukan identifikasi model berdasarkan plot ACF, PACF, dan EACF. Plot ACF mengidentifikasi ordo untuk MA baik dari komponen musiman maupun non-musiman, sementara plot PACF mengidentifikasi orde untuk AR baik dari komponen musiman maupun non-musiman. Plot EACF digunakan sebagai tambahan model tentatif yang tidak teridentifikasi sebelumnya pada plot ACF dan PACF.



Gambar 6. (a) Plot PACF dan (b) Plot EACF Data Latih Stasioner

Dari plot ACF pada Gambar 5(b), terlihat dari *lag* ke-1 tidak ada yang signifikan dan juga pada komponen musiman ada kecenderungan *tails off* pada pola ACF-nya. Sementara, dari plot PACF pada Gambar 6(a), komponen non-musiman juga tidak ada yang signifikan pada *lag* awal, sedangkan pada komponen musiman menunjukkan adanya pola *cuts off* pada *lag* ke-12 yang merupakan *lag* musiman pertama sehingga mengindikasikan adanya proses AR. Dari plot EACF pada Gambar 6(b), terbentuk 3 model tentatif pada komponen non-musiman. Model tentatif yang terbentuk adalah SARIMAX(0,1,0)(1,0,0)¹², SARIMAX(0,1,1)(1,0,0)¹² dan SARIMAX(1,1,1)(1,0,0)¹². Selanjutnya pemodelan dilakukan terhadap keseluruhan data latih dengan tambahan matriks eksogen *dummy*.

Tabel 2. Model Tentatif SARIMAX

Model Tentatif	Parameter	Koefisien	P-value	AIC
SARIMAX (0,1,0)(1,0,0) ¹²	SAR1	0,484	$< 2,2 \times 10^{-16}$ *	3175,897
	X1	-257,159	$2,7 \times 10^{-13}$ *	
	X2	-262,982	$1,3 \times 10^{-7}$ *	
	X3	-176,718	0,004*	
SARIMAX (0,1,1)(1,0,0) ¹²	MA1	-0,031	$4,2 \times 10^{-5}$ *	3164,790
	SAR1	0,485	$< 2,2 \times 10^{-16}$ *	
	X1	-395,086	$< 2,2 \times 10^{-16}$ *	
	X2	-490,497	$1,3 \times 10^{-13}$ *	
SARIMAX (1,1,1)(1,0,0) ¹²	X3	-362,354	$3,5 \times 10^{-8}$ *	3156,698
	AR1	-0,4857	$5,0 \times 10^{-5}$ *	
	MA1	0,1035	0,485	
	SAR1	0,5031	$< 2,2 \times 10^{-16}$ *	
	X1	-417,776	$< 2,2 \times 10^{-16}$ *	
	X2	-532,402	$< 2,2 \times 10^{-16}$ *	
	X3	-416,023	$7,9 \times 10^{-11}$ *	

Model tentatif terbaik yang terbentuk adalah model SARIMAX(0,1,1)(1,0,0)¹² dengan AIC sebesar 3164,790 dan seluruh parameter signifikan. Meskipun nilai AIC dari model SARIMAX(1,1,1)(1,0,0)¹² lebih kecil, model tersebut memiliki parameter yang tidak signifikan. Selain itu, selisih AIC keduanya tidak terlalu besar, sehingga model yang dipilih adalah model yang seluruh parameternya signifikan karena jika parameter SARIMAX tidak signifikan, berarti kontribusinya terhadap model tidak berbeda dari nol, akibatnya komponen tersebut tidak benar-benar diperlukan. Selanjutnya dilakukan *overfitting* dari model tentatif terbaik. Hasilnya tertera pada Tabel 3.

Tabel 3. Model *Overfitting* SARIMAX

Model <i>Overfitting</i>	Parameter	Koefisien	P-value	AIC
SARIMAX (0,1,2)(1,0,0) ₁₂	MA1	-0,034	$3,4 \times 10^{-5*}$	3157,334
	MA2	0,177	0,002*	
	SAR1	0,525	$< 2,2 \times 10^{-16*}$	
	X1	-404,621	$< 2,2 \times 10^{-16*}$	
	X2	-500,462	$5,0 \times 10^{-14*}$	
	X3	-398,674	$3,8 \times 10^{-9*}$	
	MA1	-0,3294	$3,3 \times 10^{-6*}$	
SARIMAX (0,1,1)(2,0,0) ₁₂	SAR1	0,3948	$9,6 \times 10^{-12*}$	3158,366
	SAR2	0,1949	0,003*	
	X1	-418,574	$< 2,2 \times 10^{-16*}$	
	X2	-535,565	$< 2,2 \times 10^{-16*}$	
	X3	-362,334	$7,4 \times 10^{-8*}$	
	MA1	-0,3062	$6,5 \times 10^{-5*}$	
	SAR1	0,9889	$< 2,2 \times 10^{-16*}$	
SARIMAX (0,1,1)(1,0,1) ₁₂	SMA1	-0,8828	$< 2,2 \times 10^{-16*}$	3140,642
	X1	-410,1810	$< 2,2 \times 10^{-16*}$	
	X2	-519,5794	$9,9 \times 10^{-14*}$	
	X3	-361,5296	$2,7 \times 10^{-7*}$	

Hasil *overfitting* menunjukkan bahwa seluruh model memiliki nilai AIC yang lebih rendah dari model tentatif terbaik dan seluruh parameter dari setiap modelnya signifikan. Pemilihan model SARIMAX terbaik dilakukan berdasarkan nilai AIC terkecil, sehingga didapat model terbaik yang didapat adalah SARIMAX (0,1,1)(1,0,1)¹² dengan nilai AIC sebesar 3140,642 dan seluruh parameter signifikan. Selanjutnya, dilakukan uji diagnostik model terbaik untuk memeriksa kelayakan model yang hasilnya disajikan pada Tabel 4.

Tabel 4. Hasil Uji Diagnostik Model SARIMAX Terbaik

Uji	Hipotesis Nol	p-value	Kesimpulan
Anderson-Darling	Sisaan menyebar normal	1,52e-14	Sisaan tidak menyebar normal
Ljung-Box	Sisaan saling bebas	0,4283	Sisaan saling bebas
Ljung-Box ²	Ragam sisaan homogen	0,0515	Ragam sisaan homogen
One Sample t-test	Nilai tengah sisaan sama dengan nol	0,2987	Nilai tengah sisaan sama dengan nol

Berdasarkan hasil uji diagnostik, sisaan model menunjukkan bahwa sebagian besar asumsi telah terpenuhi. Uji Ljung-Box mengindikasikan tidak adanya autokorelasi, uji Ljung-Box² menunjukkan ragam sisaan yang homogen, dan uji t satu-sampel memastikan bahwa nilai tengah sisaan tidak berbeda secara signifikan dari nol. Meskipun asumsi

normalitas sisaan tidak terpenuhi, hal tersebut dapat ditoleransi dengan Teorema Limit Pusat yang menyatakan pada ukuran sampel yang besar, sifat asimtotik dari *estimator* berbasis maksimum *likelihood* mendorong distribusi sisaan mendekati normal. Secara keseluruhan, karakteristik sisaan mendukung kelayakan model untuk analisis lebih lanjut.

3.3 Pemodelan LSTM

Proses pemodelan LSTM diawali dengan normalisasi data menggunakan MinMaxScaler untuk meningkatkan stabilitas pembelajaran dan membantu model mengenali pola dengan lebih efisien. Data yang telah dinormalisasi kemudian diubah ke dalam format *supervised learning* agar model dapat mempelajari hubungan antara input dan output. Selanjutnya, dilakukan eksperimen *hyperparameter* melalui *grid search* dengan menguji variasi *batch size*, jumlah *epoch*, dan *learning rate*. Setiap kombinasi dievaluasi menggunakan metrik MAPE dan RMSE, dan konfigurasi dengan nilai kesalahan terkecil dipilih sebagai *hyperparameter* optimal bagi model LSTM.

Tabel 5. Rata-rata MAPE dan RMSE untuk Kombinasi Hyperparameter


Model	Batch Size	Epoch	Learning Rate	MAPE	RMSE
1	16	50	0,01	7,49	103.565,95
2			0,001	9,02	130.527,26
3		100	0,01	7,81	105.109,74
4			0,001	10,14	146.431,79
5	32	50	0,01	7,54	104.220,69
6			0,001	12,66	190.002,74
7		100	0,01	7,82	111.063,22
8			0,001	7,53	105.785,55
9	64	50	0,01	7,62	106.403,39
10			0,001	9,07	125.391,26
11		100	0,01	8,20	109.579,99
12			0,001	10,01	144.750,35

Tabel 5 menyajikan hasil evaluasi berbagai konfigurasi *hyperparameter* pada model LSTM yang dibangun untuk memprediksi jumlah wisatawan mancanegara. Variasi dilakukan pada *batch size*, jumlah *epoch*, dan *learning rate* untuk mengidentifikasi kombinasi yang menghasilkan performa terbaik. Berdasarkan nilai MAPE dan RMSE, konfigurasi dengan *batch size* 16, *epoch* 50, dan *learning rate* 0,01 menunjukkan kinerja optimal, dengan MAPE sebesar 7,49 dan RMSE sebesar 103.565,95. Hasil ini mengindikasikan bahwa konfigurasi tersebut mampu menangkap pola pergerakan wisman secara lebih akurat dibandingkan kombinasi *hyperparameter* lainnya. Temuan ini juga menunjukkan sensitivitas model LSTM terhadap perubahan *learning rate* dan jumlah *epoch*, sehingga pemilihan *hyperparameter* yang tepat berperan penting dalam meningkatkan akurasi prediksi.

3.4 Perbandingan Model

Perbandingan model dimulai dengan membuat visualisasi kinerja model disajikan melalui plot yang membandingkan data uji dengan nilai *fitted* dari model SARIMAX dan LSTM pada Gambar 7. Dengan perbandingan visual tersebut, konsistensi dan kedekatan

prediksi terhadap nilai observasi dapat diamati secara lebih komprehensif sebelum dilakukan evaluasi kuantitatif lebih lanjut. Dari plot perbandingan tersebut, terlihat bahwa plot LSTM lebih mampu menangkap pola fluktuatif data uji dan lebih dekat dengan data aktual dibandingkan plot prediksi SARIMAX.



Gambar 7. Plot Perbandingan Prediksi SARIMAX dan LSTM terhadap Data Uji

Selain itu, perbandingan model dilakukan dengan menggunakan dua metrik evaluasi utama, yaitu RMSE dan MAPE. RMSE digunakan untuk mengukur besar rata-rata kesalahan prediksi dalam satuan asli data, sehingga sensitif terhadap error yang besar. Sementara itu, MAPE memberikan gambaran tentang persentase kesalahan relatif, sehingga membantu menilai akurasi model secara proporsional terhadap nilai aktual.

Tabel 6. Hasil Perbandingan Model dengan Nilai MAPE dan RMSE Data Uji

Model	RMSE	MAPE
SARIMAX	123.288,40	8,53
LSTM	106.089,12	7,46

Hasil evaluasi terhadap data wisman menunjukkan bahwa model LSTM memiliki performa prediksi yang lebih unggul dibandingkan model SARIMAX. Hal ini terlihat dari nilai RMSE pada LSTM sebesar 106.089,12 yang lebih rendah dibandingkan SARIMAX sebesar 123.288,40, menandakan bahwa LSTM menghasilkan rata-rata kesalahan prediksi dalam satuan jumlah wisman yang lebih kecil. Selain itu, nilai MAPE pada LSTM sebesar 7,46% juga lebih baik daripada SARIMAX yang mencapai 8,53%, sehingga menunjukkan bahwa secara persentase kesalahan prediksi relatif terhadap nilai aktual, LSTM mampu merepresentasikan dinamika jumlah wisman dengan lebih akurat. Temuan ini mengindikasikan bahwa LSTM lebih mampu menangkap pola kompleks dalam pergerakan jumlah wisman dibandingkan model berbasis *time series* konvensional.

Performa LSTM yang lebih baik dibandingkan SARIMAX dapat dijelaskan melalui kemampuan dasarnya dalam mempelajari pola data yang lebih kompleks. Struktur *memory cell* pada LSTM, membuat model ini mampu menangkap hubungan jangka panjang dan pola yang tidak sepenuhnya linear. Di sisi lain, SARIMAX bekerja dengan asumsi linearitas sehingga lebih cocok untuk pola data yang stabil dan teratur. Data wisman cenderung memiliki fluktuasi tajam, perubahan musiman, dan tren yang dinamis, sehingga LSTM dapat beradaptasi lebih baik sehingga menghasilkan prediksi yang lebih akurat.

4. Kesimpulan

Penelitian ini menunjukkan bahwa SARIMAX berhasil membentuk model yang layak dengan nilai AIC terkecil dan pemenuhan sebagian besar uji diagnostik. Model ini mampu menangkap pola tren dan musiman secara cukup baik, meskipun masih menghadapi keterbatasan dalam merepresentasikan fluktuasi tajam pada data kunjungan wisatawan mancanegara. Sementara itu, proses tuning hyperparameter pada model LSTM menghasilkan konfigurasi optimal yang secara signifikan meningkatkan akurasi prediksi.

Perbandingan performa menunjukkan bahwa LSTM unggul atas SARIMAX berdasarkan nilai MAPE dan RMSE pada data uji, yang mencerminkan kesalahan prediksi lebih rendah baik secara persentase maupun absolut. Keunggulan model ini didukung oleh kemampuan LSTM dalam mempelajari pola non-linear dan keterkaitan jangka panjang pada data, yang tidak sepenuhnya dapat ditangkap oleh pendekatan statistik konvensional seperti SARIMAX. Dengan demikian, LSTM lebih sesuai digunakan untuk peramalan data kunjungan wisatawan yang bersifat dinamis dan kompleks.

Daftar Pustaka

- [1] N. Fairuuz, F. Nofrian, and D. Desmintari, "Peranan Jumlah Wisatawan Asing, Nilai Tukar, dan PMDN dalam Sektor Pariwisata terhadap Pendapatan Devisa Pariwisata Indonesia," *Jurnal Indonesia Sosial Sains*, vol. 3, no. 04, pp. 694–707, Apr. 2022, doi: 10.59141/jiss.v3i04.570.
- [2] O. B. Bangun, "Peran Pariwisata dalam Peningkatan Devisa Negara," Medan, 2023. Accessed: Dec. 19, 2025. [Online]. Available: <https://circle-archive.com/index.php/carc/article/view/223>
- [3] J. H. V. Purba, R. Fathiah, and S. Steven, "The Impact of Covid-19 Pandemic on The Tourism Sector in Indonesia," *Riset*, vol. 3, no. 1, pp. 389–401, Mar. 2021, doi: 10.37641/riset.v3i1.82.
- [4] S. Paludi, "Setahun Pandemi Covid-19 dan Dampaknya Terhadap Industri Pariwisata Indonesia," *Equilibrium: Jurnal Penelitian Pendidikan dan Ekonomi*, vol. 19, no. 01, pp. 49–60, Jan. 2022, doi: 10.25134/equi.v19i01.4337.
- [5] A. Restikadewi, E. S. Ramadhan, and A. A. A. Islam, "The Impact of COVID-19 on the Tourism Sector in Indonesia," *Sebelas Maret Business Review*, vol. 6, no. 1, p. 47, Dec. 2021, doi: 10.20961/smbr.v6i1.56133.
- [6] S. Amelia, "Peran Diplomasi Pariwisata Indonesia dalam Meningkatkan Kunjungan Wisatawan Mancanegara Melalui Program Wonderful Indonesia (2019-2023)," Bandar Lampung, Dec. 2024. Accessed: Dec. 19, 2025. [Online]. Available: https://www.researchgate.net/publication/387067085_Peran_Diplomasi_Pariwisata_Indonesia_dalam_Meningkatkan_Kunjungan_Wisatawan_Mancanegara_Melalui_Program_Wonderful_Indonesia_2019-_2023
- [7] I. Rochayati, U. D. Syafitri, and I. M. Sumertajaya, "Kajian Model Peramalan Kunjungan Wisatawan Mancanegara dan di Bandara Kualanamu Medan Tanpa dan Dengan Kovariat," *Indonesian Journal of Statistics and Its Applications*, vol. 3, no. 1, pp. 18–32, Feb. 2019, doi: 10.29244/ijsa.v3i1.171.
- [8] A. Lisnawati, S. Alam, and I. Kurniawan, "Aplikasi Prediksi Kedatangan Wisatawan Mancanegara ke Indonesia dengan Algoritma Long Short-Term Memory (LSTM),"

- JATI (Jurnal Mahasiswa Teknik Informatika)*, vol. 9, no. 5, pp. 8343–8349, Jul. 2025, doi: 10.36040/jati.v9i5.15055.
- [9] Z. Zeinawaqi and A. A. Dzikrullah, "Factors Affecting The Number Of Domestic Flights In Indonesia During Covid-19 Pandemic Using SARIMAX Method," *Jurnal Matematika, Statistika dan Komputasi*, vol. 21, no. 1, pp. 1–9, Sep. 2024, doi: 10.20956/j.v21i1.34557.
- [10] A. D. Milniadi and N. O. Adiwijaya, "Analisis Perbandingan Model ARIMA dan LSTM dalam Peramalan Harga Penutupan Saham (Studi Kasus: 6 Kriteria Kategori Saham Menurut Peter Lynch)," *SIBATIK JOURNAL: Jurnal Ilmiah Bidang Sosial, Ekonomi, Budaya, Teknologi, dan Pendidikan*, vol. 2, no. 6, pp. 1683–1692, May 2023, doi: 10.54443/sibatik.v2i6.798.
- [11] D. K. Nurfatimah, "Perbandingan Performa LSTM, BI-LSTM," IPB University, Bogor, 2025. Accessed: Dec. 03, 2025. [Online]. Available: <http://repository.ipb.ac.id/handle/123456789/168439>
- [12] J. Cahyani, S. Mujahidin, and T. P. Fiqar, "Implementasi Metode Long Short Term Memory (LSTM) untuk Memprediksi Harga Bahan Pokok Nasional," *Jurnal Sistem dan Teknologi Informasi (JustIN)*, vol. 11, no. 2, p. 346, Jul. 2023, doi: 10.26418/justin.v11i2.57395.
- [13] N. Ananda, H. S. Wicaksana, Y. G. Wijaya, and R. Hijazi, "Hyperparameter Tuning LSTM Sebagai Estimator Sensor Relative Humidity Pada Automatic Weather Station Berbasis Simulated Annealing," *Buletin Meteorologi, Klimatologi, dan Geofisika*, vol. 4, no. 1, pp. 35–43, Feb. 2023, Accessed: Dec. 03, 2025. [Online]. Available: https://www.balai2bmkg.id/index.php/buletin_mkg/article/view/66
- [14] Z. Budiarmo, "Optimizing LSTM with Grid Search and Regularization Techniques to Enhance Accuracy in Human Activity Recognition," *Journal of Applied Data Sciences*, vol. 5, no. 4, pp. 2002–2014, Dec. 2024, doi: 10.47738/jads.v5i4.433.
- [15] Y. I. Ajunu, N. Achmad, and M. R. F. Payu, "Perbandingan Metode Autoregressive Integrated Moving Average dan Metode Double Exponential Smoothing dari Holt dalam Meramalkan Nilai Impor di Indonesia," *Jambura Journal of Probability and Statistics*, vol. 1, no. 1, pp. 37–46, May 2020, doi: 10.34312/jjps.v1i1.5393.